


II. Retropropagation pour un neurone seul



A) Si'enceur = $E(k) = (\hat{y}^{(k)} - y^{(k)})^2$ $E_{\text{totale}} = \frac{1}{P} \sum_{k=0}^{P-1} (\hat{y}^{(k)} - y^{(k)})^2$

$x=0,1,2$ $\frac{\partial E^{(k)}}{\partial w_i} = 2 \cdot g'(x^{(k)}) \cdot [\hat{y}^{(k)} - y^{(k)}] \cdot x_i^{(k)}$
 $= 2 \cdot g \times (1 - g) \times \begin{cases} 1 \rightarrow \frac{\partial E^{(k)}}{\partial w_0} \\ x_1 \rightarrow \frac{\partial E^{(k)}}{\partial w_1} \\ x_2 \rightarrow \frac{\partial E^{(k)}}{\partial w_2} \end{cases}$

$\Delta w_i = -\alpha \frac{\partial E}{\partial w_i}$

$= -\alpha \times 2 \sum_{k=0}^{P-1} g^{(k)} \times [1 - g^{(k)}] \times \begin{cases} 1 & \text{pour } \Delta w_0 \\ x_1^{(k)} & \text{pour } \Delta w_1 \\ x_2^{(k)} & \text{pour } \Delta w_2 \end{cases}$

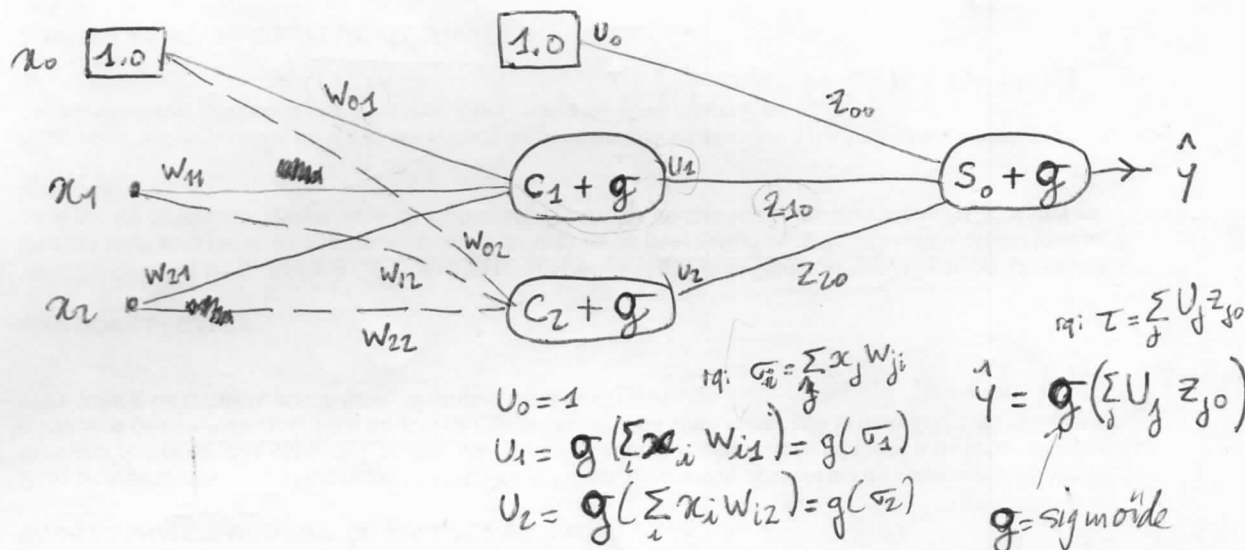
B) Si'enceur = $C(k) = -[y^{(k)} \log \hat{y}^{(k)} + (1 - y^{(k)}) \log (1 - \hat{y}^{(k)})]$

$\frac{\partial C^{(k)}}{\partial w_i} = -[y^{(k)} \frac{g'}{\hat{y}^{(k)}} x_i^{(k)} + (1 - y^{(k)}) \frac{-g'}{1 - \hat{y}^{(k)}} x_i^{(k)}]$
 $= -g'(x^{(k)}) \times x_i^{(k)} \left[\frac{y^{(k)}}{\hat{y}^{(k)}} - \frac{(1 - y^{(k)})}{(1 - \hat{y}^{(k)})} \right]$
 $= -g'(x^{(k)}) \cdot x_i^{(k)} \frac{y^{(k)}(1 - \hat{y}^{(k)}) - \hat{y}^{(k)}(1 - y^{(k)})}{\hat{y}^{(k)}(1 - \hat{y}^{(k)})}$

$= (-1) \cdot \frac{g'(x^{(k)})}{\hat{y}^{(k)}(1 - \hat{y}^{(k)})} \cdot x_i^{(k)} (y^{(k)} - \hat{y}^{(k)}) = x_i^{(k)} [-y^{(k)} + \hat{y}^{(k)}]$
 $= 1 \text{ si } g = \text{sigmoïde}$

$\Delta w_i = -\alpha \frac{\partial C}{\partial w_i} = -\alpha \sum_k (\hat{y}^{(k)} - y^{(k)}) x_i^k = -\alpha \sum_k (\hat{y}^{(k)} - y^{(k)}) \times \begin{cases} 1 \\ x_1^k \\ x_2^k \end{cases}$

Retropropagation pour un perceptron de type XOR.



1) Retropropagation sur les z_{00}, z_{10}, z_{20} (corrections à effectuer)

A) si $E^{(k)} = (\hat{y}^{(k)} - y^{(k)})^2$, un calcul identique à celui de page 1 (retropropagation sur un neurone seul) en substituant U_i à x_i , donne:

$$\Delta z_{i0} = -\alpha \times \frac{2}{P} \sum_k g(\sum_j U_j z_{j0}) [1 - g(\sum_j U_j z_{j0})] U_i^{(k)} (\hat{y}^{(k)} - y^{(k)})$$

$$= -\frac{2\alpha}{P} \sum_k \hat{y}^{(k)} [1 - \hat{y}^{(k)}] U_i^{(k)} = -\frac{2\alpha}{P} \sum_k \hat{y}^{(k)} [1 - \hat{y}^{(k)}] \begin{cases} 1 \\ U_1^{(k)} \\ U_2^{(k)} \end{cases}$$

B) si $C^{(k)} = \text{Logloss}$, un calcul identique à la page 1 donne:

$$\Delta z_{i0} = -\alpha \sum_k (\hat{y}^{(k)} - y^{(k)}) U_i^{(k)} = -\alpha \sum_k (\hat{y}^{(k)} - y^{(k)}) \begin{cases} 1 \\ U_1^{(k)} \\ U_2^{(k)} \end{cases}$$

2) Retropropagation de l'erreur sur U_1 et U_2 (si $C^{(k)} = \text{Logloss}$)

$$\frac{\partial C^{(k)}}{\partial U_1} = \frac{\partial C^{(k)}}{\partial \hat{y}^{(k)}} \times \frac{\partial \hat{y}^{(k)}}{\partial U_1} \quad \text{avec:} \quad \frac{\partial \hat{y}^{(k)}}{\partial U_1} = g'(\sum_j U_j z_{j0}) \times z_{10} = \hat{y}^{(k)} (1 - \hat{y}^{(k)}) \times z_{10}$$

$$\frac{\partial C^{(k)}}{\partial U_1} = \frac{[\hat{y}^{(k)} - y^{(k)}]}{\hat{y}^{(k)}(1 - \hat{y}^{(k)})} \times \hat{y}^{(k)} (1 - \hat{y}^{(k)}) z_{10} = [\hat{y}^{(k)} - y^{(k)}] z_{10}$$

$$\frac{\partial C^{(k)}}{\partial U_2} = [\hat{y}^{(k)} - y^{(k)}] z_{20}$$

De même:

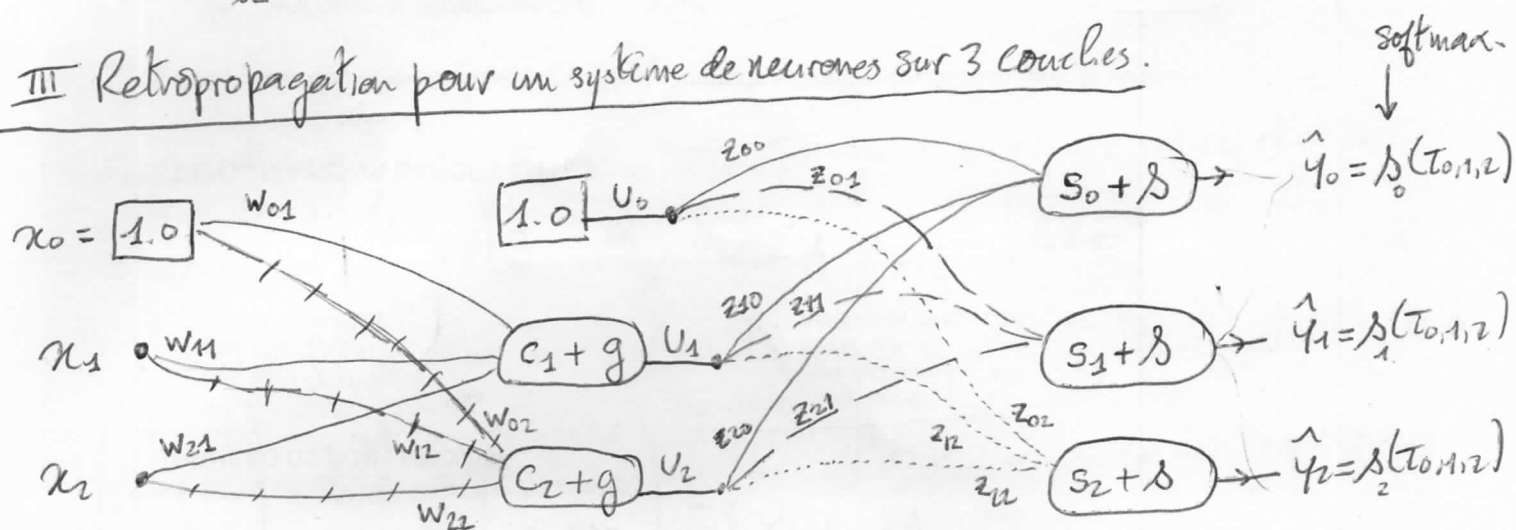
$$\frac{\partial C^{(k)}}{\partial U_2} = [\hat{y}^{(k)} - y^{(k)}] z_{20}$$

Donc: $\frac{\partial C^{(k)}}{\partial \sigma_1} = \frac{\partial C^{(k)}}{\partial U_1} \times \frac{\partial U_1}{\partial \sigma_1} = [\hat{y}^{(k)} - y^{(k)}] z_{10} \times U_1 (1 - U_1)$ car $g = \text{sigmoïde}$ donc $g'(\sigma_1) = U_1 (1 - U_1)$
 $\frac{\partial C^{(k)}}{\partial \sigma_2} = \frac{\partial C^{(k)}}{\partial U_2} \times \frac{\partial U_2}{\partial \sigma_2} = [\hat{y}^{(k)} - y^{(k)}] z_{20} \times U_2 (1 - U_2)$ $g'(\sigma_2) = U_2 (1 - U_2)$

Donc: $\frac{\partial C^{(k)}}{\partial w_{i1}} = \frac{\partial C^{(k)}}{\partial \sigma_1} \times \frac{\partial \sigma_1}{\partial w_{i1}} = [\hat{y}_1^{(k)} - y_1^{(k)}] z_{10} \times U_1 (1 - U_1) \times x_i^{(k)}$

$\frac{\partial C^{(k)}}{\partial w_{i2}} = \frac{\partial C^{(k)}}{\partial \sigma_2} \times \frac{\partial \sigma_2}{\partial w_{i2}} = [\hat{y}_2^{(k)} - y_2^{(k)}] z_{20} \times U_2 (1 - U_2) \times x_i^{(k)}$

III Retropropagation pour un système de neurones sur 3 couches.



$$\begin{aligned} U_0 &= 1.0 \\ U_1 &= g(\sigma_1) \\ \sigma_1 &= \sum_i w_{i1} \times x_i \\ U_2 &= g(\sigma_2) \\ \sigma_2 &= \sum_i x_i w_{i2} \\ g &= \text{sigmoïde} \end{aligned}$$

$$T_0 = \sum_j U_j z_{j0}$$

$$T_1 = \sum_j U_j z_{j1}$$

$$T_2 = \sum_j U_j z_{j2}$$

$$\hat{y}_0 = e^{T_0} / (e^{T_0} + e^{T_1} + e^{T_2})$$

$$\hat{y}_1 = e^{T_1} / (e^{T_0} + e^{T_1} + e^{T_2})$$

$$\hat{y}_2 = e^{T_2} / (e^{T_0} + e^{T_1} + e^{T_2})$$

rq: $\hat{y}_0 + \hat{y}_1 + \hat{y}_2 = 1$ toujours

rq: vraie valeur:

$$\begin{aligned} (y_0, y_1, y_2) &= (1, 0, 0) \text{ si classe } \phi \\ &= (0, 1, 0) \text{ si classe } 1 \\ &= (0, 0, 1) \text{ si classe } 2 \end{aligned}$$

donc: $y_0 + y_1 + y_2 = 1$

Fonction de coût: log loss

$$C^{(k)} = - \sum_{i=0}^2 y_i^{(k)} \text{Log}(\hat{y}_i^{(k)})$$

$$= - y_0^{(k)} \text{Log}(\hat{y}_0^{(k)}) - y_1^{(k)} \text{Log}(\hat{y}_1^{(k)}) - y_2^{(k)} \text{Log}(\hat{y}_2^{(k)})$$

Donc: $\frac{\partial C^{(k)}}{\partial \hat{y}_i} = - y_i^{(k)} \times \frac{1}{\hat{y}_i^{(k)}}, i=0,1,2.$

Puis: $\frac{\partial C^{(k)}}{\partial \tau_i} = \frac{\partial C^{(k)}}{\partial \hat{y}_0} \times \frac{\partial \hat{y}_0}{\partial \tau_i} + \frac{\partial C^{(k)}}{\partial \hat{y}_1} \times \frac{\partial \hat{y}_1}{\partial \tau_i} + \frac{\partial C^{(k)}}{\partial \hat{y}_2} \times \frac{\partial \hat{y}_2}{\partial \tau_i}$

et il faut calculer les $\partial \hat{y}_j / \partial \tau_i$, $j=0,1,2$, $i=0,1,2$.

Synthèse du II (apprentissage du perceptron XOR) [cf p2 et 3]

3 bis

Pour chaque échantillon "k" du jeu de données:

1) entrée: $x_0^{(k)} = 1$ \rightarrow sortie: \hat{y}_k
 $x_1^{(k)} = \text{longueur pétale}$
 $x_2^{(k)} = \text{longueur sépale}$
 (car y_k une valeur)

2) calcul $\delta_{\text{sortie}}^{(k)} = \hat{y}_k - y_k$

3) calcul correction sur z_{00}, z_{10}, z_{20} (pds entre couches cachées et de sortie)
 $(\Delta z_{i0})^{(k)} = -\alpha \delta_{\text{sortie}}^{(k)} \begin{pmatrix} 1 \\ U_{10}^{(k)} \\ U_{20}^{(k)} \end{pmatrix} = \begin{pmatrix} \Delta z_{00} \\ \Delta z_{10} \\ \Delta z_{20} \end{pmatrix}$

• calcul de l'erreur sur les σ_i (avant application de la fonction d'activation de la couche cachée).

$$\begin{pmatrix} \frac{\partial C}{\partial \sigma_1} \\ \frac{\partial C}{\partial \sigma_2} \end{pmatrix} = \vec{\delta}_{\text{caché}}^{(k)} = \begin{pmatrix} \delta_{\text{caché}}^{(k)1} \\ \delta_{\text{caché}}^{(k)2} \end{pmatrix} = \begin{pmatrix} (\hat{y}_k - y_k) z_{10} U_1 (1 - U_1) \\ (\hat{y}_k - y_k) z_{20} U_2 (1 - U_2) \end{pmatrix}$$

4) calcul de correction sur les poids w_{ij} (entre couche d'entrée et couche cachée)

$$\frac{\partial C}{\partial w_{i1}} = \delta_{\text{caché}}^{(k)1} \times x_i^{(k)}$$

$$\frac{\partial C}{\partial w_{i2}} = \delta_{\text{caché}}^{(k)2} \times x_i^{(k)} \quad (i=0,1,2)$$

$$(\Delta w_{i1})^{(k)} = -\alpha \delta_{\text{caché}}^{(k)1} \times x_i^{(k)}$$

$$(\Delta w_{i2})^{(k)} = -\alpha \delta_{\text{caché}}^{(k)2} \times x_i^{(k)}$$

$$\frac{\partial \hat{y}_0}{\partial \tau_0} = \frac{e^{\tau_0} (e^{\tau_0} + e^{\tau_1} + e^{\tau_2}) - e^{\tau_0} e^{\tau_0}}{(e^{\tau_0} + e^{\tau_1} + e^{\tau_2})^2} = \frac{e^{\tau_0} (e^{\tau_1} + e^{\tau_2})}{(e^{\tau_0} + e^{\tau_1} + e^{\tau_2})^2} = \frac{e^{\tau_0}}{(e^{\tau_0} + e^{\tau_1} + e^{\tau_2})} - \left(\frac{e^{\tau_0}}{(e^{\tau_0} + e^{\tau_1} + e^{\tau_2})} \right)^2 \quad 4$$

$$= \hat{y}_0 (1 - \hat{y}_0)$$

$$\frac{\partial \hat{y}_0}{\partial \tau_1} = \frac{e^{\tau_0} (-e^{\tau_1})}{(e^{\tau_0} + e^{\tau_1} + e^{\tau_2})^2} = -\hat{y}_0 \cdot \hat{y}_1 \quad \text{et} \quad \frac{\partial \hat{y}_0}{\partial \tau_2} = -\hat{y}_0 \cdot \hat{y}_2$$

De même: $\frac{\partial \hat{y}_1}{\partial \tau_0} = -\hat{y}_1 \hat{y}_0$, $\frac{\partial \hat{y}_1}{\partial \tau_1} = \hat{y}_1 (1 - \hat{y}_1)$, $\frac{\partial \hat{y}_1}{\partial \tau_2} = -\hat{y}_1 \cdot \hat{y}_2$

et $\frac{\partial \hat{y}_2}{\partial \tau_0} = -\hat{y}_2 \hat{y}_0$, $\frac{\partial \hat{y}_2}{\partial \tau_1} = -\hat{y}_1 \hat{y}_2$, $\frac{\partial \hat{y}_2}{\partial \tau_2} = \hat{y}_2 (1 - \hat{y}_2)$

En synthèse:

$$\frac{\partial \hat{y}_i}{\partial \tau_j} = \begin{cases} \hat{y}_i (1 - \hat{y}_i) & \text{si } i=j \\ -\hat{y}_i \cdot \hat{y}_j & \text{si } i \neq j \end{cases}$$

Donc: $\frac{\partial C^{(k)}}{\partial \tau_0} = \frac{\partial C^{(k)}}{\partial \hat{y}_0} \cdot \frac{\partial \hat{y}_0}{\partial \tau_0} + \frac{\partial C^{(k)}}{\partial \hat{y}_1} \cdot \frac{\partial \hat{y}_1}{\partial \tau_0} + \frac{\partial C^{(k)}}{\partial \hat{y}_2} \cdot \frac{\partial \hat{y}_2}{\partial \tau_0}$

$$= -\frac{y_0}{\hat{y}_0} \cdot \hat{y}_0 (1 - \hat{y}_0) - \frac{y_1}{\hat{y}_1} \cdot (-\hat{y}_1 \hat{y}_0) - \frac{y_2}{\hat{y}_2} \cdot (-\hat{y}_2 \hat{y}_0)$$

$$= -y_0 (1 - \hat{y}_0) + y_1 \hat{y}_0 + y_2 \hat{y}_0 = -y_0 + \hat{y}_0 (y_0 + y_1 + y_2)$$

= 1 car somme de proba
bilites

$$= \hat{y}_0 - y_0$$

De même: $\frac{\partial C^{(k)}}{\partial \tau_1} = \hat{y}_1 - y_1$

$$\frac{\partial C^{(k)}}{\partial \tau_2} = \hat{y}_2 - y_2$$

On peut alors calculer les dérivées partielles de la fonction de coût par rapport à tous les poids w_{ij} , z_{jk} , ainsi que celles par rapport à U_0 , U_1 , U_2 (retropropagation des erreurs)
(la correction par descente de gradient)

~~$\frac{\partial C^{(k)}}{\partial z_{jk}} = \frac{\partial C^{(k)}}{\partial \hat{y}_k} \cdot \frac{\partial \hat{y}_k}{\partial z_{jk}}$~~ car z_{jk} n'intervient que dans le calcul de \hat{y}_k et pas les autres

~~$= \frac{\partial C^{(k)}}{\partial \hat{y}_k} \cdot \frac{\partial \hat{y}_k}{\partial z_{jk}} \cdot \frac{\partial z_{jk}}{\partial z_{jk}}$~~ car z_{jk} n'intervient que dans le calcul de \hat{y}_k et pas les autres

~~$= \frac{y_k - \hat{y}_k}{\hat{y}_k (1 - \hat{y}_k)} \cdot U_j$~~

~~$= -\frac{y_k - \hat{y}_k}{\hat{y}_k (1 - \hat{y}_k)} U_j$~~

de qui donne la correction à effectuer sur le poids w_{jk}

~~$\Delta z_{jk} = -\alpha \frac{\partial C^{(k)}}{\partial z_{jk}} = -\alpha \left(-\frac{y_k - \hat{y}_k}{\hat{y}_k (1 - \hat{y}_k)} U_j \right)$~~

$$\frac{\partial C^{(p)}}{\partial z_{jh}} = \frac{\partial C^{(p)}}{\partial \tau_k} \times \frac{\partial \tau_k}{\partial z_{jh}}$$

car z_{jh} n'intervient que dans le calcul de τ_k et pas les autres

$$= (\hat{y}_k - y_k) \times U_j$$

ce qui donne la correction à effectuer sur le poids z_{jh} :

$$\Delta z_{jh} = -\alpha \sum_p \frac{\partial C^{(p)}}{\partial z_{jh}} = -\alpha \sum_p (\hat{y}_k - y_k) \times U_j$$

la rétropropagation des erreurs commises en sortie de réseau vers les entrées en couche cachée (sur U_1, U_2) s'est: $\partial C^{(p)} / \partial U_j$, $j=1,2$.

$$\begin{aligned} \frac{\partial C^{(p)}}{\partial U_j} &= \frac{\partial C^{(p)}}{\partial \tau_0} \times \frac{\partial \tau_0}{\partial U_j} + \frac{\partial C^{(p)}}{\partial \tau_1} \times \frac{\partial \tau_1}{\partial U_j} + \frac{\partial C^{(p)}}{\partial \tau_2} \times \frac{\partial \tau_2}{\partial U_j} \\ &= (\hat{y}_0 - y_0) \times z_{j0} + (\hat{y}_1 - y_1) z_{j1} + (\hat{y}_2 - y_2) z_{j2} \end{aligned}$$

de plus: $\frac{\partial U_j}{\partial w_{ij}} = g'(\sigma_j) \times \frac{\partial \sigma_j}{\partial w_{ij}} = U_j (1 - U_j) \times x_i$

↑
sigmoïde

car sigmoïde:
 $g'(\sigma_j) = U_j (1 - U_j)$

Donc:

$$\frac{\partial C^{(p)}}{\partial w_{ij}} = \frac{\partial C^{(p)}}{\partial U_j} \times \frac{\partial U_j}{\partial w_{ij}}$$

car w_{ij} n'intervient que dans le calcul de U_j et pas les autres

$$= [(\hat{y}_0 - y_0) z_{j0} + (\hat{y}_1 - y_1) z_{j1} + (\hat{y}_2 - y_2) z_{j2}] U_j (1 - U_j) x_i = \frac{\partial C^{(p)}}{\partial U_j} \times U_j (1 - U_j) x_i$$

la correction à effectuer sur w_{ij} est alors:

$$\Delta w_{ij} = -\alpha \sum_p \frac{\partial C^{(p)}}{\partial w_{ij}} = -\alpha \sum_p \frac{\partial C^{(p)}}{\partial U_j} \times U_j (1 - U_j) x_i$$

En synthèse:

a) appelons $\delta_k^{(p)} = \tau_k^{(p)} - y_k^{(p)}$ le vecteur erreur produite en couche de sortie pour l'échantillon (p) . (q: activation = softmax)

b) la correction à appliquer aux poids z_{jh} reliant la couche de sortie et la couche cachée est:

$$\Delta z_{jh} = -\alpha \sum_{(p)} \delta_k^{(p)} \times U_j^{(p)}$$

c) la rétropropagation des erreurs de la couche de sortie vers la couche cachée est:

$$\delta_j^{(p)} = \frac{\partial C^{(p)}}{\partial U_j} = \sum_k \delta_k^{(p)} z_{jk} \xrightarrow{\text{avant correction}} \delta_j^{(p)} = \frac{\partial C}{\partial U_j} !!$$

d) la correction à appliquer aux poids w_{ij} reliant la couche cachée et la couche d'entrée est: $\Delta w_{ij} = -\alpha \sum_{(p)} \delta_j^{(p)} U_j (1 - U_j) x_i$ (q: activation = sigmoïde)

Synthèse du III (apprentissage réseau 3 couches de 3 neurones) [p.3,4,5]

5 bis

Pour chaque échantillon p du jeu de données:

1) entrée $x_0^{(p)} = 1$ \rightarrow sortie: $\hat{y}_0^{(p)}, \hat{y}_1^{(p)}, \hat{y}_2^{(p)}$
 $x_1^{(p)} = \text{longueur pétale}$
 $x_2^{(p)} = \text{largeur pétale}$
 (rq: $y_0^{(p)}, y_1^{(p)}, y_2^{(p)} = \text{vraie valeur}$)

2) calcul erreur de sortie:

$$\vec{\delta}_{\text{sortie}} = \frac{\partial C}{\partial T_{0,1,2}} = \begin{pmatrix} \hat{y}_0^{(p)} - y_0^{(p)} \\ \hat{y}_1^{(p)} - y_1^{(p)} \\ \hat{y}_2^{(p)} - y_2^{(p)} \end{pmatrix} = \begin{pmatrix} \hat{y}^{(p)} - y^{(p)} \end{pmatrix} \quad \delta_{\text{sortie } k}^{(p)} = \frac{\partial C}{\partial T_k}$$

3) calcul correction sur les poids z_{jk} entre couche cachée et couche sortie.

$$\Delta z_{jk}^{(p)} = -\alpha \delta_k^{(p)} \times U_j^{(p)} / (\text{Nb échantillons}) \rightarrow \text{pour obtenir une correction moyenne}$$

$\delta_k^{(p)}$: tous les neurones de sortie.
 $U_j^{(p)}$: tous les neurones cachés.

\rightarrow calcul de l'erreur sur les σ_i (avant application de la fonction d'activation de la couche cachée)

$$\begin{pmatrix} \partial C / \partial \sigma_1 \\ \partial C / \partial \sigma_2 \end{pmatrix} = \vec{\delta}_{\text{caché}} = \begin{pmatrix} \text{caché} \\ \delta_1^{(p)} \\ 1 \text{ couche} \\ \text{caché} \\ \delta_2^{(p)} \\ 2 \text{ couche} \end{pmatrix} \quad \text{avec: } \delta_j^{(p)} = \left(\sum_k \delta_k^{(p)} z_{jk} \right) \times U_j (1 - U_j)$$

$\delta_k^{(p)}$: neurones couche sortie
 $U_j (1 - U_j)$: dérivée sigmoïde

4) calcul correction sur les poids w_{ij} (entre couche entrée et couche cachée)

$$\Delta w_{ij}^{(p)} = -\alpha \delta_j^{(p)} \times x_i^{(p)} / (\text{Nb échantillons})$$

rq: si l'on avait défini $\delta_j^{(p)} = \frac{\partial C}{\partial U_j}$ on aurait obtenu: $\delta_j^{(p)} = \sum_k \delta_k^{(p)} z_{jk}$

C'est: $\frac{\partial C}{\partial \sigma_j} = \frac{\partial C}{\partial U_j} \times \frac{\partial U_j}{\partial \sigma_j}$
 $= \frac{\partial C}{\partial U_j} \times g'(\sigma_j)$
 $= \frac{\partial C}{\partial U_j} \times U_j (1 - U_j)$

mais le facteur $U_j (1 - U_j)$ serait disparu

donc $\Delta w_{ij}^{(p)} = -\alpha \delta_j^{(p)} \times U_j (1 - U_j) \times x_i^{(p)}$

des calculs se généralisent au cas où il y a plusieurs couches cachées

A) entre couche de sortie et dernière couche cachée :

a). $\delta_k^{(p)} = \hat{y}_k^{(p)} - y_k^{(p)}$, $k = 0, \dots$ tous les neurones de sortie

$\hat{y}_k^{(p)}$: prediction
 $y_k^{(p)}$: vraie valeur

a). $\Delta z_{jk} = \frac{-\alpha}{\text{Nb échantillon}} \sum_{(p)} \delta_k^{(p)} \times U_j^{(p)}$, $j = \text{tous les neurones de la dernière couche cachée}$

$\delta_k^{(p)}$: production couche cachée
 $U_j^{(p)}$: tous les neurones de la couche de sortie

b). $\delta_j^{(p)} = \sum_k \delta_k^{(p)} z_{jk}$

$\delta_k^{(p)}$: couche sortie
 z_{jk} : poids entre couche de sortie et dernière couche cachée (valeur à prendre avant correction)

B) entre deux couches cachées, si $\delta_j^{(p)}$ est défini par : $\delta_j^{(p)} = \frac{\partial C^{(p)}}{\partial U_j}$

a). $\delta_j^{(p)} = \sum_k \delta_k^{(p)} z_{jk}$

$\delta_k^{(p)}$: couche cachée aval
 z_{jk} : poids entre les couches cachées amont et aval (valeur à prendre avant correction)

b). $\Delta z_{jk} = \frac{-\alpha}{\text{Nb échantillon}} \sum_{(p)} \delta_k^{(p)} U_k (1 - U_k) x_j$

$\delta_k^{(p)}$: couche aval
 $U_k (1 - U_k)$: production neurones aval
 x_j : production neurones amont

* Si $\delta_j^{(p)}$ est défini par : $\delta_j^{(p)} = \frac{\partial C^{(p)}}{\partial U_j} = \frac{\partial C^{(p)}}{\partial U_j} \times \frac{\partial U_j}{\partial U_j} = U_j (1 - U_j) \times \frac{\partial C^{(p)}}{\partial U_j}$

$\frac{\partial C^{(p)}}{\partial U_j}$: sortie de la couche précédente avant application de la sigmoïde

a). $\delta_j^{(p)} = \sum_k \delta_k^{(p)} x_{jk} \times U_j (1 - U_j)$

$\delta_k^{(p)}$: couche cachée aval
 x_{jk} : production

b). $\Delta z_{jk} = \frac{-\alpha}{\text{Nb échantillon}} \sum_{(p)} \delta_k^{(p)} \times x_j$

$\delta_k^{(p)}$: couche aval
 x_j : production neurones amont